

APLICAÇÃO DE REDES NEURAIS ARTIFICIAIS PARA A PREVISÃO DE DEMANDA DE UM RESTAURANTE UNIVERSITÁRIO

LUCAS BARDUCO MATHEUS
GILBERTO CLÓVIS ANTONELLI

Resumo

Uma boa estratégia na administração baseada em dados históricos pode ser determinante para o desenvolvimento sustentável e sucesso financeiro de um negócio, no caso de uma Unidade de Alimentação e Nutrição (UAN), uma melhor previsão de clientes diários baseada nestes dados tem como consequência a diminuição de desperdícios alimentares. Este trabalho criou um modelo capaz de prever o número de refeições servidas diariamente no Restaurante Universitário da Universidade Estadual de Maringá, com um erro percentual médio de 12%, utilizando o processamento de dados históricos do restaurante para treinamento e aprendizagem de máquina através de Redes Neurais Artificiais (RNA), estrutura inspirada no funcionamento do cérebro humano, a qual mostrou confiabilidade nas previsões realizadas e potencial de aprimoramento com refinamento de parâmetros e um bom tratamento de dados.

Palavras-chave: *Redes Neurais Artificiais; previsão de demanda; Unidade de Alimentação de Nutrição.*

1. Introdução

As Unidades de Alimentação e Nutrição (UAN) são espaços dedicados ao preparo e entrega de refeições nutricionalmente equilibradas de acordo com o perfil do consumidor, ela é conceitualmente considerada uma unidade de trabalho ou órgão de uma empresa que desenvolve atividades relacionadas à alimentação e nutrição, independentemente da posição que ocupa na escala hierárquica da entidade (CARDOSO et al., 2005), sendo o principal objetivo da UAN é servir refeições nutricionalmente saudáveis e higienicamente seguras, no sentido de manter e/ou recuperar a saúde do cliente para auxiliar no desenvolvimento de hábitos alimentares saudáveis (PROENÇA et al., 2005).

O sucesso de uma organização para Abreu (2007) é baseado nos processos pelo qual ela opera, podendo ser o processo administrativo o responsável. Este processo pode ser definido como as várias funções do administrador de UAN como um todo. O Planejamento, organização, direção e controle, constituem as funções administrativas. Quando visualizadas na sua

abordagem total para o alcance de objetivos, tais como a qualidade de um serviço forma o processo administrativo.

A gestão realizada através do processo administrativo, envolve atividades administrativas, técnicas e operacionais como ressalta Teixeira et al (2000), sendo evidente que os objetivos da UAN devem sempre ser considerados com atenção especial, a fim de que a atuação profissional esteja sempre voltada à sua consecução.

Buscando os conceitos de minimização de erros dentro da previsão de refeições diárias, tem-se a escolha de aplicação dos conceitos de Redes Neurais Artificiais (RNA) dentro de um modelo de previsão de demanda. O funcionamento dos neurônios presentes no cérebro humano inspirou a combinação por meio de modelos matemáticos conhecida como Redes Neurais Artificiais. Associada à inteligência artificial, as RNA têm a capacidade de adquirir e acumular conhecimento em seu ambiente, se adaptando a diversos parâmetros e situações. Seu funcionamento pode superar o cérebro humano em termos de armazenamento de históricos de informações, além de serem mais ágeis em cálculos excessivos, por não serem afetados por cansaço e distrações, que poderiam levar o cérebro humano ao erro (HAYKIN, 2001).

Dentro deste aspecto, o treinamento e aprimoramento de uma rede neural artificial é visado e aplicado em diversas áreas teóricas e práticas para aperfeiçoamento de resultados, como previsão de demanda em diversos setores (CAIRES & SIMONELLI; CARDOSO, 2021), auxílio na identificação, diagnóstico e análise na área da saúde (SANTOS; SKEIKA; VOGADO, 2019), estimativas e cálculos para a agropecuária (ABRAGAM, 2019; ALCÂNTRA, 2015; AZEVEDO, 2017), auxílio nos estudos sobre fatores climáticos (DANTAS, 2015; MOREIRA, 2017), previsões dentro de estudos biológicos (MORAIS, 2010; VENDRUSCOLO, 2015), entre demais áreas que se beneficiam da aplicação de RNA.

Mediante os conceitos e inúmeras aplicações vantajosas das Redes Neurais Artificiais, como a previsão de demanda considerando fatores de relevância para o modelo, o reconhecimento de padrões de comportamento, e o cruzamento de características para cálculo de probabilidades, este trabalho tem o objetivo de construir um modelo de previsão para o número de refeições diárias servidas no Restaurante Universitário da Universidade Estadual de Maringá (UEM). Relacionando as diversas variáveis que podem contribuir para a flutuação de demanda das refeições, dentre elas, dia da semana, mês, semestre e cardápio à capacidade de aprendizado e adaptação das RNA, espera-se obter com maior assertividade a previsão do

número de refeições a serem servidas no restaurante, para diminuição de desperdícios dentro da UAN e maior economia dentro da gestão administrativa em geral.

2. Revisão da literatura

2.1 Unidade de Alimentação e Nutrição (UAN's)

As Unidades de Alimentação e Nutrição são centros focados em proporcionar refeições saudáveis e equilibradas, atendendo às necessidades nutricionais de seus consumidores. Segundo Cardoso et al. (2005), a UAN é uma unidade de trabalho ou órgão da empresa que desenvolve práticas relacionadas à alimentação e nutrição, independentemente da posição hierárquica na organização. O objetivo primordial da UAN, conforme Proença et al. (2005), é preservar ou recuperar a saúde dos usuários por meio de uma alimentação adequada e segura, sempre de acordo com as normas de vigilância sanitária e contribuir para o estabelecimento de hábitos alimentares saudáveis.

Com o objetivo de preparar refeições balanceadas para funcionários, servidores e acadêmicos, o Restaurante Universitário (RU) da Universidade Estadual de Maringá (UEM) foi criado em 1979. Atualmente, ele serve até 1600 refeições diárias para uma comunidade de mais de 30 mil pessoas, incluindo professores e alunos. Contudo, a demanda por alimentos pode variar sazonalmente, sem uma correlação clara, tornando importante um planejamento claro para evitar excessos. Embora o RU esteja comprometido com a redução do desperdício de alimentos, ainda não possui um sistema preciso para contar o número de refeições servidas diariamente, baseando-se apenas na experiência dos usuários e em uma média aritmética simples de registros históricos.

De acordo com Abreu (2007), o sucesso de uma organização é baseado em seus processos operacionais, especialmente o processo administrativo, que engloba as funções de planejamento, organização, direção e controle. Este processo é crucial para alcançar objetivos de qualidade de serviço.

O restaurante da UEM é uma importante Unidade de Alimentação e Nutrição que tem como objetivo fornecer nutrientes adequados para a saúde dos seus usuários. De acordo com Teixeira et al (2000), a gestão efetiva da UAN envolve uma combinação de atividades administrativas, técnicas e operacionais. Embora o funcionamento da UAN possa ser complexo, como destacado por Fonseca & Santana (2012), é crucial que os objetivos da UAN sejam

sempre considerados com atenção especial. O presente estudo pretende abordar os fatores de influência na gestão que compõem o processo administrativo na Unidade de alimentação e nutrição da universidade, buscando minimizar os desperdícios por meio de uma melhor previsão de clientes diários.

O restaurante universitário da UEM, localizado em Maringá, Paraná, tem cerca de 800 lugares e atende a uma comunidade de 30 mil pessoas, incluindo docentes e discentes. O RU pode servir até 1600 refeições por dia, incluindo almoço e janta. Os dados utilizados neste estudo foram coletados durante três anos de funcionamento da UAN, de 04 de abril de 2016 a 14 de dezembro de 2018, totalizando 985 dias. As informações foram organizadas diariamente, incluindo o número de clientes atendidos para o almoço e janta, e os dados da ementa. Os dados são propriedade da equipe de administração do RU.

2.2 Previsão de Demanda

No plano teórico, Kotler (1991) define a demanda como o volume consumido por uma quantidade determinada de clientes de um mercado específico, sob condições de ambientes e temporais determináveis. Giro outro, quanto ao plano prático, a demanda demonstra-se como um agente imprevisível, sendo dificilmente projetado com exatidão. Sem embargo da possibilidade de reconhecer e identificar padrões, notório é o fato de que eventos inesperados podem alterar drasticamente a demanda, porém, nada impede o planejamento e preparo que as organizações devem realizar de maneira a enfrentar as incertezas da demanda, ainda que as variações tornem penosas as análises e projeções de venda.

No aspecto geral, é possível identificar padrões na demanda os produtos e serviços de forma sazonal. Ainda que a sazonalidade apresente uma melhor previsibilidade, fatores externos podem reduzir as capacidades de vendas, como por exemplo variação de clima e condições econômicas, tornando as previsões incertas e complexas. De maneira complementar, vê-se que até mesmo pequenas variações de um período temporal menor, pode alterar substancialmente a complexidade das decisões quanto as previsões. (SLACK et al., 2009).

No mesmo passo, Corrêa (2000) elenca vários fatores que formulam o processo próspero de previsões, sendo necessário: Obter o maior número de informações possíveis; Tratar corretamente estas informações; Análisar padrões existentes possibilitam o uso de métodos quantitativos em series temporais; Considerar fatores qualitativos relevantes; Fazer projeção de padrões; Verificar a estimativa de erros. A aplicação desta metodologia descrita

culmina em um processo de previsão mais eficaz e positivo, que caminhará a organização em direção de seus objetivos.

O modelo algoritmo procura imitar as atividades biológicas dentro de uma célula nervosa, sendo uma simplificação do modelo de um neurônio e tendo capacidades de processamento similares. A rede é composta por neurônios, que processam as entradas através da combinação linear de seus pesos com as entradas e aplicam uma função de ativação.


2.3 Redes Neurais Artificiais

A arquitetura e o algoritmo de aprendizagem são as duas facetas fundamentais de uma rede neural artificial. Esta divisão é derivada do modo como a rede é treinada. O algoritmo de aprendizagem generaliza os dados e armazena o conhecimento dentro dos pesos adaptáveis da rede. Assim, o construtor de um sistema de RNA tem duas opções: escolher o tipo de rede adequado para resolver o problema e escolher o algoritmo para treinar a rede e ajustar seus pesos. A natureza do problema a ser resolvido influencia nas possibilidades de escolha de redes e algoritmos de aprendizagem (RAUBER, 2005).

A Figura 1 mostra-se o modelo de um neurônio artificial de MCCULLOCH & PITTS (1943 apud RAUBER, 2005, p. 5-6). Os dados de entrada enviados por outros neurônios entram em D entradas x_j (= sinapse). Cada entrada x_j consiste em uma combinação linear das entradas, cada uma com um peso w_j , que determina a relevância dentro da combinação da rede, que é resultado da função (1):

$$net = w_1x_1 + w_2x_2 + \dots + w_Dx_D = \sum_{j=1}^D w_jx_j = \underline{w}^T \underline{x} \quad (1)$$

Figura 1 - Modelo de um neurônio de McCulloch e Pitts com função alterada para ativação ReLU.




Fonte: Adaptado de RAUBER (2005)

2.3.1 Arquitetura de Rede Neural Artificial

A arquitetura de uma Rede Neural Artificial é decisiva para resolver diferentes tipos de problemas e é determinada por quatro fatores importantes: número de camadas, número de nós por camada, tipo de conexão entre nós, e a topologia da rede. Quanto ao número de camadas, existem RNAs com uma única camada que possuem apenas um nó entre a camada de entrada e saída e são limitadas a solucionar problemas linearmente separáveis. Por outro lado, as RNAs com múltiplas camadas possuem mais de um neurônio entre a entrada e saída. As conexões entre nós podem ser do tipo *feedforward* (ou acíclico), em que a saída de um nó só pode ser usada como entrada para nós em camadas posteriores, ou do tipo feedback (cíclico), onde a saída de um nó pode ser usada como entrada para um nó na mesma camada ou camada inferior (FIORIN, 2011). Quando há realimentação da saída nas camadas de entrada, a RNA é chamada de recorrente. Algumas das principais categorias de RNAs incluem Perceptrons, Adalines, Perceptrons de Múltiplas Camadas (MLP), Memórias Matriciais, Self-Organizing, Processamento Temporal, entre outras, com mais detalhes sobre suas topologias disponíveis em referências sobre o assunto (BRAGA, 2000; BEALE & JACKSON, 1990).

O tipo MLP da RNAs é uma rede que contém uma ou mais camadas intermediárias ou ocultas. Estas redes são amplamente utilizadas por serem fáceis de implementar e possuem uma certa simplicidade. O MLP é exemplificado na Figura 2 com três entradas, duas camadas intermediárias com quatro neurônios cada e uma camada de saída com um único neurônio que produz uma única informação de saída (FIORIN, 2011).

Figura 2 - Representação gráfica de uma RNA - MLP com duas camadas intermediárias.



Fonte: FIORIN (2011)

A capacidade computacional do MLP é reforçada pelas suas camadas intermediárias, permitindo trabalhar com dados que não sejam linearmente separáveis. Enquanto redes com apenas uma camada intermediária são capazes de representar qualquer função contínua, aquelas com duas ou mais camadas podem, teoricamente, implementar qualquer função, independentemente de ser linearmente separável ou não. A precisão dos resultados produzidos pela RNA está diretamente ligada ao número de nodos nas camadas intermediárias (CYBENKO, 1988).

2.3.2 Aprendizagem de Rede Neural Artificial

A aprendizagem em Redes Neurais é um processo descrito por Haykin (2001) que implica a adaptação dos parâmetros livres da rede em resposta ao ambiente em que a mesma está inserida. Durante este processo, a RNA é estimulada pelo ambiente e suas modificações nos parâmetros levam a uma nova resposta ao ambiente. Este processo de aprendizagem é realizado por meio de treinamento, que consiste em ajustes iterativos aos pesos sinápticos da RNA (MIRANDA et al., 2009). A rede neural extrai informações relevantes dos padrões de entrada, ajustando seus parâmetros para obter uma representação própria do problema (EYNG, 2008).

A rede pode ser treinada de duas formas, sendo elas aprendizado supervisionado e aprendizado não supervisionado (BISHOP, 1995; FLECK, 2016). No aprendizado supervisionado, um supervisor fornece a saída desejada, permitindo a comparação com a saída da RNA e ajustes aos pesos para minimizar o erro. No aprendizado não supervisionado, a rede neural procura correlações ou redundâncias nos dados de entrada sem a intervenção de um supervisor.

O critério de erro máximo pode ser utilizado para validar a rede neural artificial, garantindo que sua utilização dentro de uma determinada faixa de operação não resultará em erros maiores que o erro máximo previsto (ALVES SOBRINHO et al., 2011). De acordo com Ambrósio (2002), a aprendizagem por correção de erro consiste em ajustes aos pesos das conexões entre os neurônios para minimizar o erro de saída, ou seja, a diferença entre o resultado previsto pela RNA e o resultado desejado. Matematicamente, esse sinal de erro é definido pela equação (2):

$$e_j(n) = d_j(n) - y_j(n) \quad (2)$$

Onde o sinal de erro e do neurônio j no instante n (passo de tempo do processo de iteração envolvido na aprendizagem) é igual a saída desejada d para esse neurônio menos a sua saída efetivamente obtida.

2.3.2.1 Regra de Aprendizado por Retropropagação (Backpropagation)

Para o treinamento da Rede Neural Artificial, foi desenvolvido um sistema de backpropagation utilizando um otimizador Adam com frequência de aprendizagem baseada no decaimento exponencial. Keras.io (2023) explica que a otimização de Adam é um método de descida de gradiente estocástico baseado na estimativa adaptativa de momentos de primeira e segunda ordem. Segundo Kingma et al. (2014 apud Keras.io, 2023), o método é "computacionalmente eficiente, requer pouca memória, invariante ao reescalonamento diagonal de gradientes e é adequado para problemas que são grandes em termos de dados/parâmetros", com isso, TensorFlow (2022) elabora que ao treinar um modelo, geralmente é útil diminuir a taxa de aprendizado à medida que o treinamento avança. Essa programação aplica uma função de decaimento exponencial a uma etapa do otimizador, dada uma taxa de aprendizado inicial fornecida. A programação é necessariamente um 1-arg que produz uma taxa de aprendizado decaída quando passa pela etapa do otimizador atual. Isso pode ser útil para alterar o valor da taxa de aprendizado (Ta) em diferentes invocações de funções do otimizador. É calculado pela equação (3):

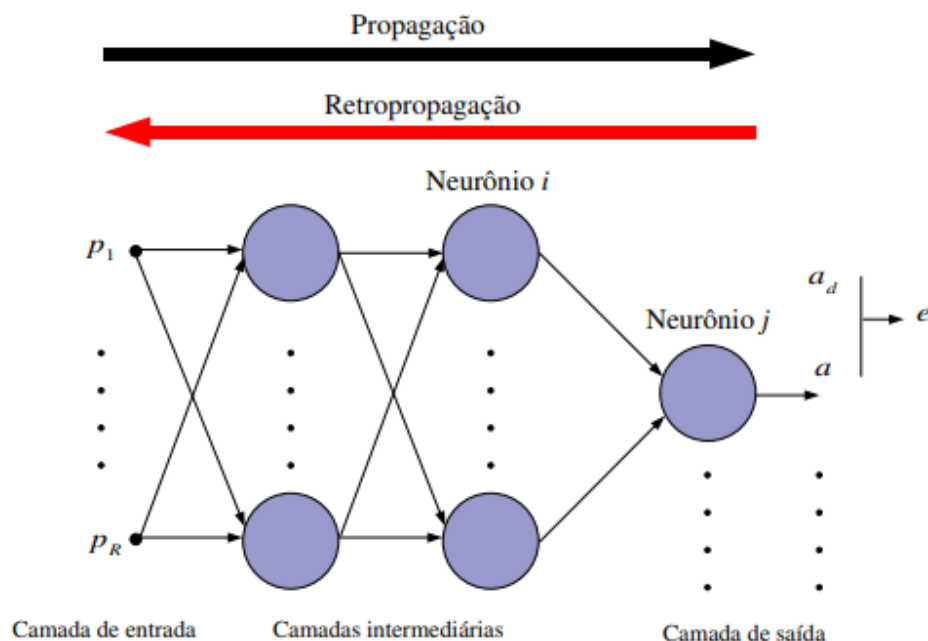
$$Ta = \text{taxa de aprendizagem inicial} * \text{taxa de decaimento} ^ \left(\frac{\text{iteração}}{\text{iterações decaídas}} \right) \quad (3)$$

No método de retropropagação, as variáveis preditivas são processadas pela RNA, que apresenta como resposta o número de refeições previsto pela própria rede, que posteriormente é comparado com o valor real correspondente. Se a diferença entre o valor previsto e o valor real for maior que o erro dado, a rede usa uma fase de realimentação, que consiste em recalcular o processo alterando o peso para cada variável e cada neurônio. Esse procedimento, chamado de treinamento, é realizado até que os parâmetros de parada inseridos sejam satisfeitos.

O algoritmo *Backpropagation* visa encontrar a menor diferença entre as saídas desejadas e as saídas obtidas pela rede neural, com o mínimo de erro, ajustando os pesos das camadas através da retropropagação do erro (HAYKIN, 1999; RUMELHART, 1986 apud MATSUNAGA, 2012). Matsunaga (2012) menciona que a técnica é um tipo de treinamento supervisionado, onde a rede é avaliada durante a sua propagação (camada a camada) e, especialmente, na sua retropropagação, que é a análise inversa à propagação. Os pesos

sinápticos da rede w_{ji} , aqueles que conectam a saída do neurônio i à entrada do neurônio j , são ajustados e fixados, com isso o padrão de entrada é aplicado as primeiras camadas da rede, que se propaga por todas as outras camadas subsequentes, até que a saída seja gerada, então este resultado é comparado com o resultado desejado, calculando o erro para cada elemento de saída, retropropagando esse sinal de erro para as camadas de saída de cada neurônio intermediário anterior, o que molda o sinal de erro total, gerando apenas a contribuição relativa de cada elemento na formação da saída original. Este processo é repetido por toda a rede até que cada elemento da rede receba sua influência relativa para o erro total, assim, os pesos são atualizados de acordo com o padrão atribuído para a correção, para que a saída futura convirja para o resultado esperado. A ilustração do algoritmo Backpropagation pode ser verificada na Figura 3.

Figura 3 - Ilustração do algoritmo Backpropagation.



Fonte: MATSUNAGA (2012)

2.4 Ferramentas Computacionais

O software utilizado para desenvolver as etapas e aplicar o algoritmo de treinamento é baseado em Python e foi executado na plataforma Jupyter Notebook com a ajuda das bibliotecas TensorFlow e Keras.

TensorFlow é uma biblioteca de código aberto criada pelo Google Brain para pesquisas e aprendizado de máquina. Ele tem se tornado popular devido ao seu desempenho ao usar o

compilador XLA para tornar a execução mais rápida em diferentes dispositivos, como CPUs, GPUs, TPUs, entre outros. Além disso, é flexível e oferece uma abstração que permite ao desenvolvedor se concentrar na lógica geral da aplicação, já o Keras é uma biblioteca implementada utilizando TensorFlow com uma interface mais simples e otimizada para casos comuns, tornando mais fácil a criação de modelos de redes neurais profundas. O objetivo final é tornar a aprendizagem profunda uma ferramenta acessível a todos, não apenas a pesquisadores e especialistas (DA MATA RIBEIRO & GUIMARÃES, 2018).

Keras.io (2023) é uma biblioteca de aprendizado de máquina em Python que fornece uma interface fácil de usar para a construção e treinamento de redes neurais. Ele permite a definição da arquitetura da rede, a escolha da função de perda, do algoritmo de otimização e das funções de ativação. O Keras é altamente personalizável e permite ajustar os hiperparâmetros do modelo para melhorar o desempenho. A API do Keras oferece uma ampla gama de recursos e funções para redes neurais, permitindo a construção de modelos sofisticados e complexos.

O algoritmo de otimização Adam é um método popular para ajustar os parâmetros da rede neural durante o treinamento. Ele combina adaptação de taxa de aprendizado e momentum para ajustar os pesos da rede neural de maneira eficiente. O Adam tem se mostrado eficaz em muitas aplicações de aprendizado de máquina.

A função de perda é uma medida de desempenho que mede a diferença entre as previsões do modelo e os rótulos conhecidos. O erro quadrático médio (mean squared error - MSE) é uma função de perda comum usada em problemas de regressão, que penaliza o modelo por fazer previsões imprecisas. Existem várias outras funções de perda disponíveis, dependendo do tipo de problema que está sendo abordado.

As funções de ativação são usadas para adicionar não-linearidade à rede neural e são aplicadas a cada neurônio em uma camada da rede. A função ReLU (unidade linear retificada) é uma função de ativação comumente usada em redes neurais que converte todos os valores negativos em zero, enquanto mantém os valores positivos iguais. Isso ajuda a evitar a saturação da função e a acelerar o treinamento da rede neural. Outras funções de ativação incluem a função sigmóide, a função tanh e a função softmax.

3. Metodologia

Este trabalho se categoriza na descrição de Da Silva & Menezes (2005), o qual trouxe uma natureza de pesquisa aplicada e quantitativa, trazendo o objetivo de aplicação prática e visando a solução de um problema considerando que tudo dentro desta relação é quantificável.

Os objetivos trazem também a visão explicativa e experimental, buscando identificar as variáveis que determinam ou contribuem para a ocorrência dos fenômenos, selecionando os elementos que seriam capazes de influenciá-lo, definindo as formas de controle e de observação dos efeitos ocasionados (GIL, 1991 apud DA SILVA & MENEZES, 2005).

3.1 Coleta e Tratamento dos Dados

O presente estudo utiliza dados fornecidos pela administração do Restaurante Universitário da Universidade Estadual de Maringá, situado no campus sede da instituição na cidade de Maringá, Paraná. Com uma história de funcionamento desde 1979, o Restaurante Universitário foi recentemente reformado e ampliado, retornando a operar em 2016 com capacidade para atender cerca de 800 pessoas, oferecendo cerca de 1600 refeições diárias para a comunidade universitária de 30 mil pessoas.

Os dados coletados se concentram em três anos de operação da UAN, de 4 de abril de 2016 a 14 de dezembro de 2018, cobrindo 985 dias incluindo fins de semana e feriados. Para cada dia de funcionamento, são registrados os dados do cardápio e o número de clientes atendidos tanto para o almoço quanto para o jantar.

O projeto se baseia em uma pesquisa anterior que utilizou a mesma base de dados e realizou as mesmas etapas de tratamento. Essa pesquisa anterior validou dois pontos importantes: a topologia da Rede Neural Artificial e as variáveis mais relevantes para o estudo, que são mês do ano, dia da semana, cardápio e evento (almoço ou jantar). Esta pesquisa parte dessas considerações e não se aprofunda nas análises derivadas da validação.

Os dados obtidos precisaram ser limpos e adequados para que o computador pudesse processá-los. Foram incluídos fatores como mês do ano, dia da semana, semestre letivo, feriado no dia anterior e no dia posterior para compor a rede a ser treinada.

A partir da limpeza e tratamento dos dados, temos 515 dias relevantes de funcionamento do restaurante, de 2016 a 2018, foram obtidos 98 variações de cardápio, mas foram

consolidados em apenas 19 opções devido à semelhança dos pratos., conforme mostrado na Tabela 1.

Tabela 1 – Códigos e itens do cardápio do restaurante

CÓDIGO	PRATO
1	ACÉM BOVINO
2	ALMÔNDÉGAS
3	ARROZ CARRETEIRO
4	BIFE ACEBOLADO/NA CHAPA/AO MOLHO/GRELHADO
5	BISTECA SUÍNA ACEBOLADA/ASSADA/FRITA/AO MOLHO/AO FORNO
6	CARNE DE PANELA
7	CARNE MOÍDA
8	CHARQUE AO MOLHO/COM MANDIOCA/COM LEGUMES
9	CUPIM ASSADO
10	FRANGO ASSADO/FRITO/AO MOLHO/XADREZ
11	HAMBURGUER
12	ISCAS DE CARNE
13	KARAGUE DO RU
14	LINGUIÇA ASSADA/AO FORNO/ACEBOLADA
15	PEIXE AO FORNO/GRELHADO/FRITO/COM LEGUMES
16	PERNIL ASSADO/ACEBOLADO
17	PICADINHO AO SUGO/AO MOLHO/COM LEGUMES
18	SASSAMI DE FRANGO FRITO
19	STROGONOFF

Fonte: Autor (2023)

O dia da semana também foi levado em conta como uma variável importante. Para representá-lo, foi atribuído um código numérico de 1 a 7, embora os dados de sábado e domingo acabassem sendo descartados devido ao fechamento do restaurante. A Tabela 2 mostra a relação dos códigos com os dias da semana.

Tabela 2 – Códigos e dias da semana

CÓDIGO	DIA DA SEMANA
1	Domingo
2	Segunda-feira
3	Terça-feira
4	Quarta-feira
5	Quinta-feira
6	Sexta-feira
7	Sábado

Fonte: Autor (2023)

A influência do mês do ano na demanda de clientes também foi analisada, com os meses sendo numerados e codificados de acordo com a Tabela 3. Assim, os dados do mês foram

incluídos na planilha de estudo. A entrada na rede neural corresponde ao código do mês referente ao dia registrado.

Tabela 3 – Códigos e meses do ano

CÓDIGO	MÊS
1	Janeiro
2	Fevereiro
3	Março
4	Abril
5	Maio
6	Junho
7	Julho
8	Agosto
9	Setembro
10	Outubro
11	Novembro
12	Dezembro

Fonte: Autor (2023)

O impacto do semestre letivo também foi examinado, adicionando-se uma coluna para representá-lo na planilha. O código do semestre foi usado como entrada na rede, conforme mostrado na Tabela 4.

Tabela 4 – Códigos e semestres

CÓDIGO	SEMESTRE
0	1º SEMESTRE
1	2º SEMESTRE

Fonte: Autor (2023)

É relevante destacar importância dos dados de entrada para o cálculo da rede neural artificial. A saída é um número inteiro representando a previsão de clientes para o almoço ou jantar, mas não inclui a demanda total do dia.


3.2 Desenvolvimento da Rede Neural Artificial

A construção da rede baseia-se fundamentalmente na rede multicamadas ocultas (Multi Layer Perceptron), por se tratar de uma base de dados grande e com várias variáveis que influenciam diretamente na saída que tornará a ser nossa previsão de clientes diários para almoço e jantar.

A rede multicamadas com base em backpropagation trouxe com si um afinamento no método de treinamento de rede, que a partir do funcionamento dela, foi se elaborado o

desenvolvimento da estrutura da rede. A partir da melhor interpretação do comportamento dos pesos e relevâncias de cada elemento pertencente a rede, foi reparado uma grande importancia de uma rede mais encorpada e com mais oportunidade de atribuição de pesos para cada camada intermediária. Com tudo em mente, tem-se a utilização da plataforma Jupyter Notebook com base na linguagem Python de programação por trazer menor custo computacional e melhor funcionamento do programa por se tratar de um local amplamente utilizado para manipulação de dados e uma linguagem leve e altamente manipulavel. Sendo assim, buscando uma alta performance computacional, foi criada uma grande rede com base de MLP, tendo 4 neurônios como Camada de entrada, 4 camadas intermediárias com 36 neurônios cada, e a camada de saída com 1 neurônio.

Figura 4 - Representação gráfica da arquitetura da rede neural.



Fonte: Autor (2023)

A rede requer treinamento para funcionar de forma eficiente, este processo envolve a atribuição de pesos sinápticos, que são as bases dos fatores que influenciam no resultado final. A topologia da rede neural gerou pesos responsáveis pela conexão dos neuronios, efetuando as iterações, tendo como resultado 4213 pesos, divididos em 180 para a primeira camada intermediária, 1332 para as outras 3 camadas seguintes e 37 conectada na camada de saída,

estes pesos são tratados como entidades separadas e ao mesmo tempo são como um único grupo ao aplicar o algoritmo de treinamento.

Neste artigo utilizamos ReLU (4):

$$f(x) = \max(0, x) \quad (4)$$

Como a função de ativação, o qual segue a a logica de que se o valor de entrada seja negativo, é atribuido um novo valor de 0 e caso seja maior que ou igual a zero, ele segue linear.

3.3 Treinamento da RNA

A função ReLU foi utilizada como função de ativação para adicionar não-linearidade à rede neural e acelerar o treinamento. O algoritmo de otimização escolhido foi o Adam, que ajustou os pesos da rede neural de maneira eficiente. A função de perda utilizada foi o erro quadrático médio (MSE), que mediu a diferença entre as previsões do modelo e os rótulos conhecidos.

O treinamento da rede neural foi realizado usando conjuntos de dados de treinamento, validação e teste correspondentes a 60, 20 e 20% dos 956 dados, respectivamente. O conjunto de treinamento foi utilizado para ajustar os parâmetros do modelo, enquanto o conjunto de validação foi usado para monitorar a precisão do modelo e evitar o overfitting. O conjunto de teste foi usado para avaliar a precisão do modelo em dados não vistos durante o treinamento.

A biblioteca Keras.io em Python foi utilizada para construir e treinar a rede neural. A API do Keras foi utilizada para definir a arquitetura da rede neural, o algoritmo de otimização, a função de perda e as funções de ativação. Durante o treinamento, o modelo ajustou seus parâmetros para minimizar a função de perda MSE. Ao final do treinamento, o modelo foi avaliado usando o conjunto de teste para avaliar sua precisão em dados não vistos. O modelo treinado pode ser usado para fazer previsões em novos dados e o processo de treinamento da rede neural é altamente personalizável, permitindo que os usuários ajustem a arquitetura da rede, o algoritmo de otimização e a função de perda para se adequarem aos seus dados e objetivos específicos.


4. Análise dos Resultados

A partir dos tratamento dos dados e do desenvolvimento da rede neural através da elaboração da rede para código python dentro do ambiente de desenvolvimento integrado Jupyter

Notebook consolidado pelas bibliotecas de código aberto TensorFlow e Keras, houve a execução dos softwares elaborados para almoço e jantar.

Para o almoço, utilizando a distribuição dos 504 dados de entrada na rede, temos resultado com correlação intraclasse de 0,9985, classificando esta amostra com replicabilidade excelente (FLEISS, 1986 cf. BioEstat, 2023), a Figura 4 representa a correlação positiva muito forte da demanda prevista com a demanda real.


Figura 5 - Representação gráfica da correlação intraclasse entre demanda prevista e demanda real dos dados referentes ao almoço.



Fonte: Autor (2023)

A rede demonstrou um erro percentual medio durante sua fase de treino (80% dos dados) de aproximadamente 5,2% e para testes (20% dos dados) de aproximadamente 12,01%, representando uma média de erro de 102 clientes diariamente. A Figura 5 representa com pontos os erros de todos os dados de teste, sendo que todas as marcações entre a linha superior (133) e a linha inferior (-133) representam 80% dos valores obtidos, demonstrando a presença de muitos *outliners* consequente da alta variação presentes em dias proximos as ferias academicas dos alunos da universidade, os quais representam a grande maioria dos clientes do restaurante universitario.


Figura 6 - Representação gráfica dos erros entre a demanda prevista e demanda real dos dados referentes ao almoço.



Fonte: Autor (2023)

Para o jantar, utilizando a distribuição dos 452 dados de entrada na rede, temos resultado com correlação intraclass de 0,9972, classificando esta amostra com replicabilidade excelente (FLEISS,1986 cf. BioEstat, 2023), a Figura 6 representa a correlação positiva muito forte da demanda prevista com a demanda real.


Figura 7 - Representação gráfica da correlação intraclass entre demanda prevista e demanda real dos dados referentes ao jantar.



Fonte: Autor (2023)

A rede demonstrou um erro percentual medio durante sua fase de treino de aproximadamente 7,36% e para testes de aproximadamente 11,67%, representando uma média de erro de 39 clientes diariamente. A Figura 7 representa com pontos os erros de todos os dados de teste, sendo que todas as marcações entre a linha superior (66) e a linha inferior (-65) representam 80% dos valores obtidos, demonstrando a presença de muitos *outliners* consequente da alta variação presentes em dias proximos ao inicio e fim das ferias academicas dos alunos da universidade, os quais representam a grande maioria dos clientes do restaurante universitario.

Figura 8 - Representação gráfica dos erros entre a demanda prevista e demanda real dos dados referentes ao almoço.




Fonte: Autor (2023)

Com base nestes dados, temos que a influência do tratamento dos dados é de suma importância dentro da confiabilidade dos resultados juntamente com a eficiencia do software, com isso, foi-se realizado uma nova execução dos softwares de previsão para almoço e jantar, porém agora com a remoção dos *outliners*, para que seja feita uma melhor conclusão da eficiencia do programa com base nos parametros e dados de entrada e tambem para analisar a influência do tratamento da base de dados no erro final de cada software executado.

Para o almoço sem os outliers, utilizando a distribuição dos 394 dados de entrada na rede, temos resultado com correlação intraclass de 0,9999, classificando esta amostra com replicabilidade excelente (FLEISS,1986 cf. BioEstat, 2023), a Figura 8 representa a correlação positiva muito forte da demanda prevista com a demanda real.


Figura 9 - Representação gráfica da correlação intraclass entre demanda prevista e demanda real dos dados referentes ao almoço sem outliers.



Fonte: Autor (2023)

A rede demonstrou um erro percentual medio durante sua fase de treino de aproximadamente 1,66% e para testes de aproximadamente 6,04%, representando uma média de erro de 59 clientes diariamente. A Figura 9 representa com pontos os erros de todos os dados de teste, sendo que todas as marcações entre a linha superior (133) e a linha inferior (-133), que anteriormente representavam 80% dos valores obtidos, agora englobam aproximadamente 90,8% dos resultados obtidos, demonstrando a diminuição significativa do erro dentro da nova execução.


Figura 10 - Representação gráfica dos erros entre a demanda prevista e demanda real dos dados referentes ao almoço sem outliers.



Fonte: Autor (2023)

Para o almoço sem os outliers, utilizando a distribuição dos 365 dados de entrada na rede, temos resultado com correlação intraclass de 0,9996, classificando esta amostra com replicabilidade excelente (FLEISS, 1986 cf. BioEstat, 2023), a Figura 10 representa a correlação positiva muito forte da demanda prevista com a demanda real.


Figura 11 - Representação gráfica da correlação intraclass entre demanda prevista e demanda real dos dados referentes ao jantar sem outliers.



Fonte: Autor (2023)

A rede demonstrou um erro percentual medio durante sua fase de treino de aproximadamente 3,28% e para testes de aproximadamente 6,8%, representando uma média de erro de 22 clientes diariamente. A Figura 11 representa com pontos os erros de todos os dados de teste, sendo que todas as marcações entre a linha superior (66) e a linha inferior (-65), que anteriormente representam 80% dos valores obtidos, agora englobam 93,4% dos resultados obtidos, demonstrando a diminuição significativa do erro dentro da nova execução.

Figura 12 - Representação gráfica dos erros entre a demanda prevista e demanda real dos dados referentes ao jantar sem outliers.



Fonte: Autor (2023)

Fica evidente a influência do tratamento de dados quando o assunto é robustez do software, fazendo com que seja um dos pilares para um bom resultado de previsões, com isso, mesmo com resultados satisfatórios, que há muito espaço para evolução e muitos métodos a se ponderar dentro das escolhas de topologia de rede, funções de ativação, método de aprendizagem e interpretação da necessidade da aplicação da rede neural. Com isso, mostra-se muito flexível e relevante dentro das diversas áreas que a rede neural vem sendo cada vez mais amplamente implementada.

5. Conclusão

O objetivo deste trabalho de conclusão de curso foi alcançado com sucesso, já que as redes neurais desenvolvidas apresentaram resultados satisfatórios com um erro percentual médio de 12% na correlação entre dados de teste da rede e os dados reais do restaurante universitário. A rede neural se mostrou relevante nas previsões de demanda futura e pode ser utilizada para estabelecer novas estratégias de eficiência e diminuição de desperdícios. Com uma análise mais e tratamento mais elaborado dos dados, é possível potencializar os resultados deste trabalho, reduzindo a variação e fortalecendo a resistência contra os outliers, que se mostraram altamente influentes dentro das previsões realizadas. A elaboração deste trabalho foi uma oportunidade para a prática dos conceitos estudados em Engenharia de Produção e integração da tecnologia em projetos influentes na sociedade é muito relevante, além disso, a recomendação de integrar base de dados e rede neural que pode ser replicada a partir dos parâmetros apresentados no Apêndice A é uma ótima forma de colocar em prática os conceitos abordados no artigo.

A integração de base de dados e rede neural é uma abordagem comum em diversos campos, desde a análise de dados até a tomada de decisão. A utilização de redes neurais permite que os dados sejam analisados de forma automatizada e precisa, tornando a tomada de decisão mais rápida e eficiente. Além disso, a atualização automática dos dados permite que as informações estejam sempre atualizadas e precisas, existem diversas ferramentas disponíveis para a integração de base de dados e rede neural, incluindo o TensorFlow e o Keras, ambos desenvolvidos pelo Google, essas ferramentas oferecem uma ampla gama de recursos para a construção e treinamento de redes neurais, bem como para a integração de dados.

Em resumo, a integração de base de dados e rede neural é uma ótima forma de aplicar os conceitos de Engenharia de Produção e tecnologia para a evolução sustentável em projetos

influentes na sociedade. É importante estar sempre atualizado com as novas ferramentas e tecnologias disponíveis, a fim de obter os melhores resultados em projetos e tomadas de decisão.

Referências

ABRAHAM, Emerson Rodolfo et al. **Estimativa da produção da soja brasileira utilizando redes neurais artificiais**. Agrarian, v. 12, n. 44, p. 261-271, 2019.

ABREU, Edeli Simioni; SPINELLI, Mônica Glória Neuman; ZANARDI, Ana Maria Pinto. **Gestão de Unidades de Alimentação e Nutrição: Um modo de fazer**. São Paulo: Metha, 2007.

Adam Class. **Keras.io**, 2023. Disponível em: <<https://keras.io/api/optimizers/adam/>>. Acessado em:07/02/23.

Adam: A Method for Stochastic Optimization. **Kingma et al.**, 2014. Disponível em: <<https://arxiv.org/abs/1412.6980>>. Acessado em:07/02/23.

ALCÂNTARA, Aline Edwiges Mazon de. **Redes neurais artificiais para prognose do crescimento e da produção de povoamentos de eucalipto em Minas Gerais**. 2015.

ALVES SOBRINHO, T.; RODRIGUES, D. B. B.; OLIVEIRA, P. T. S.; REBUCCI, L. C. S.; PERTUSSATTI, C. A. **Estimativa da evapotranspiração de referência através de redes neurais artificiais**. Revista Brasileira de Meteorologia, v.26, n.2, p. 197-203, 2011.

AMBRÓSIO, P. E. **Redes neurais artificiais no apoio ao diagnóstico diferencial de lesões intersticiais pulmonares**. 2002. Ribeirão Preto – SP. Dissertação (Mestrado) – Faculdade de Filosofia, Universidade de São Paulo.

ANTONIOLLI, Eduarda et al. **Revisão sistemática: aplicação de redes neurais para previsão do consumo de energia elétrica**. Revista de engenharia e tecnologia, v. 13, n. 2, 2021.

AZEVEDO, Alcinei M. et al. **Eficiência da estimação da área foliar de couve por meio de redes neurais artificiais**. Horticultura Brasileira, v. 35, p. 14-19, 2017.

BEALE, Russell; JACKSON, Tom. **Neural Computing-an introduction**. CRC Press, 1990.

BIOESTAT 5.3 Disponível para download em:
<https://www.mamiraua.org.br/downloads/programas/>

- BISHOP, C. M. **Neural networks for Pattern Recognition**. Clarendon Press, Oxford, 1995.
- BRAGA, A. de P.; CARVALHO, A. C. P. F.; LUDERMIR, Teresa B. **Redes neurais artificiais. Teoria e Aplicações**, 2000.
- CAIRES, Kaique Vitor Louzada; SIMONELLI, George. **Previsão da demanda brasileira de biodiesel utilizando redes neurais artificiais**. Research, Society and Development, v. 10, n. 5, p. e17410513381-e17410513381, 2021.
- CARDOSO, R.C.V.; SOUZA, E.V.A.; SANTOS, P.Q. **Unidades de alimentação e nutrição nos campus da Universidade Federal da Bahia: um estudo sob a perspectiva do alimento seguro**. Revista de Nutrição, v. 18, n. 5, p.670, set./out. 2005.
- COELHO, L. S. **Notas em Matemática Aplicada. Fundamentos, Potencialidades e Aplicações de Algoritmos Evolutivos**. Sociedade Brasileira de Matemática Aplicada e Computacional. São Carlos, BR., 2003.
- CORRÊA, Henrique L.; CORRÊA, Carlos A. **Administração de Produção E Operações: Manufatura E Serviços: Uma Abordagem Estratégica**. Editora Atlas SA, 2000.
- CYBENKO, G. **Continuous valued neural networks with two hidden layer are sufficient**, Tufts University. Medford. (Technical Report), 1988.
- DA MATA RIBEIRO, Maxwell; QUIMARÃES, Samuel Soares. **Redes neurais utilizando tensorflow e keras**. RE3C-Revista Eletrônica Científica de Ciência da Computação, v. 13, n. 1, 2018.
- DA SILVA, Edna Lucia; MENEZES, Estera Muszkat. **Metodologia da pesquisa e elaboração de dissertação**. UFSC, Florianópolis, 4a. edição, v. 123, 2005.
- DANTAS, Daniel et al. **Uso de Redes Neurais Artificiais na previsão da precipitação de períodos chuvosos**. Revista Espinhaço, 2015.
- EYNG, E. **Controle Feedforward-Feedback aplicado às colunas de absorção de produção de etanol por fermentação**. 2008. Campinas, SP. Tese (Doutorado) – Programa de Pós-Graduação em Engenharia Química, Universidade Estadual de Campinas.

FIORIN, Daniel V. et al. **Aplicações de redes neurais e previsões de disponibilidade de recursos energéticos solares.** Revista Brasileira de Ensino de Física, v. 33, p. 01-20, 2011.

FLECK, Leandro et al. **Redes neurais artificiais: Princípios básicos.** Revista Eletrônica Científica Inovação e Tecnologia, v. 1, n. 13, p. 47-57, 2016.

FLEISS, Joseph L. **Analysis of data from multiclinic trials. Controlled clinical trials,**1986.

GIL, Antonio Carlos. **Como elaborar projetos de pesquisa.** São Paulo: Atlas, 1991.

HAYKIN, S. **Neural Networks: a comprehensive foundation.** New York: MacMillan College Publishing Co., 1999.

HAYKIN, S. **Redes neurais: princípios e prática.** 2ª Edição. Porto Alegre: Bookman, 2001.

KOTLER, Philip. **Administração de marketing: análise, planejamento, implementação e controle.** In: Administração de marketing: análise, planejamento, implementação e controle. 1994.

MATSUNAGA, Victoria Yukie. **Curso de Redes Neurais utilizando o MATLAB.** Belém do Pará, 2012.

MCCULLOCH, Warren S.; PITTS, Walter. **A logical calculus of the ideas immanent in nervous activity.** The bulletin of mathematical biophysics, v. 5, p. 115-133, 1943.

MIRANDA, F. A.; FREITAS, S. R. C.; FAGGION, P. L. **Integração e interpolação de dados de anomalias ar livre utilizando-se a técnica de RNA e krigagem.** Boletim de Ciências Geodésicas, v.15, n.3, p. 428-443, 2009.

MORAIS, Emerson Cordeiro. **Reconhecimento de padrões e redes neurais artificiais em predição de estruturas secundárias de proteínas.** Universidade Federal do Rio de Janeiro. Programa de Engenharia de Sistemas e Computação. Rio de Janeiro, 2010.

MOREIRA, Artur Ferreira et al. **Utilização de uma Rede Neural Artificial como Algoritmo de Controle de um Robô Ackerman em Ambiente Simulado.** Mostra Nacional de Robótica., 2017.

PROENÇA, R.P.C.; SOUSA, A.A.; VIEIROS, M.B.; HERING, B. **Qualidade nutricional e sensorial na produção de refeições.** Nutrição em Pauta, Campinas, v. 13, n. 75, p.4-16, nov./dez.2005.

RAMOS, Sabrina Alves et al. **AVALIAÇÃO QUALITATIVA DO CARDÁPIO E PESQUISA DE SATISFAÇÃO EM UMA UNIDADE DE ALIMENTAÇÃO E NUTRIÇÃO.** Brazilian Journal of Food & Nutrition/Alimentos e Nutrição, v. 24, n. 1, 2013.

RAUBER, Thomas Walter. **Redes neurais artificiais.** Universidade Federal do Espírito Santo, v. 29, 2005.

RICARTE, Michelle Pinheiro Rabelo et al. **Avaliação do desperdício de alimentos em uma unidade de alimentação e nutrição institucional em Fortaleza-CE.** Saber Científico (1982 792X), v. 1, n. 1, p. 158-175, 2021.

RUMELHART, David E.; HINTON, Geoffrey E.; WILLIAMS, Ronald J. **Learning representations by back-propagating errors.** nature, v. 323, n. 6088, p. 533-536, 1986.

SANTOS, Hellen Geremias dos et al. **Machine learning para análises preditivas em saúde: exemplo de aplicação para prever óbito em idosos de São Paulo, Brasil.** Cadernos de Saúde Pública, v. 35, p. e00050818, 2019.

SKEIKA, Everton Leonardo et al. **Utilização de redes neurais completamente convolucionais para identificação e medição de crânios fetais.,** 2019. Dissertação de Mestrado. Universidade Tecnológica Federal do Paraná.

SLACK, Nigel et al. **Administração da produção.** São Paulo: Atlas, 2009.

TEIXEIRA, S; MILET, Z; CARVALHO, J; BISCONTINI, T. M. **Administração aplicada: Unidades de Alimentação e Nutrição.** São Paulo: Atheneu. 2010.

tf.keras.optimizers.schedules.ExponentialDecay. **TensorFlow**, 2022. Disponível em: <https://www.tensorflow.org/api_docs/python/tf/keras/optimizers/schedules/ExponentialDecay>. Acessado em:07/02/23.

VENDRUSCOLO, Diogo Guido Streck et al. **Estimativa da altura de eucalipto por meio de regressão não linear e redes neurais artificiais**. Revista brasileira de biometria, v. 33, n. 4, p. 556-569, 2015.

VOGADO, Luis HS et al. **Rede neural convolucional para o diagnóstico de leucemia**. In: Anais do XIX Simpósio Brasileiro de Computação Aplicada à Saúde. SBC, 2019. p. 46-57.

Apêndice A – Parâmetros definidos para o Software utilizando Keras

Tabela 1 A – Parâmetros do Software

Arquitetura	MLP
Função de Ativação	ReLU
Número de Camadas	6
Número de Neurônios na Camada de Entrada	4
Número de Neurônios nas Camadas Ocultas	36/36/36/36
Número de Neurônios na Camada de Saída	1
Função de Perda	MSE
Otimizador	Adam
Taxa de Aprendizado	0,001
Número de Épocas	10000
Validação	20%

Fonte: Autoria Própria (2023)