

Trabalho de Conclusão de Curso
Engenharia de Produção

APLICAÇÃO DE REDES NEURAIS ARTIFICIAIS PARA A PREVISÃO DE DEMANDA DE UM RESTAURANTE UNIVERSITÁRIO

Lucas Barduco Matheus

Orientador: Gilberto Clóvis Antonelli

Objetivo do Estudo

Problema raiz

- Previsão de demanda de um Restaurante Universitário.

Abordagem de solução

- Utilização de Redes Neurais Artificiais.

Revisão Bibliográfica

Restaurante Universitário da Universidade Estadual de Maringá

- O restaurante universitário da UEM é uma importante Unidade de Alimentação e Nutrição que tem como objetivo fornecer nutrientes adequados para a saúde dos seus usuários.
- Localiza-se em Maringá, Paraná, tem cerca de 800 lugares e atende a uma comunidade de 30 mil pessoas, incluindo docentes e discentes. O RU pode servir até 1600 refeições por dia, incluindo almoço e janta.

Unidade de Alimentação e Nutrição (UAN)

- UANs são espaços dedicados ao preparo e entrega de refeições nutricionalmente equilibradas. Ela é considerada uma unidade de trabalho ou órgão de uma empresa que desenvolve atividades relacionadas à alimentação e nutrição (CARDOSO et al., 2005).
- Segundo Abreu (2007) o sucesso da organização é baseado nos processos pelo qual ela opera, podendo ser o processo administrativo o responsável. Este processo pode ser definido como as várias funções do administrador de UAN como um todo, sendo elas O Planejamento, organização, direção e controle.

Revisão Bibliográfica

Previsão de Demanda

- Kotler (1991) a demanda demonstra-se como um agente imprevisível, sendo dificilmente projetado com exatidão. Sem embargo da possibilidade de reconhecer e identificar padrões, notório é o fato de que eventos inesperados podem alterar drasticamente a demanda.

Revisão Bibliográfica

Redes Neurais Artificiais

- O funcionamento dos neurônios presentes no cérebro humano inspirou a combinação por meio de modelos matemáticos conhecida como Redes Neurais Artificiais. Associada à inteligência artificial, as RNA têm a capacidade de adquirir e acumular conhecimento em seu ambiente, se adaptando a diversos parâmetros e situações. Seu funcionamento pode superar o cérebro humano em termos de armazenamento de históricos de informações, além de serem mais ágeis em cálculos excessivos, por não serem afetados por cansaço e distrações, que poderiam levar o cérebro humano ao erro (HAYKIN, 2001).
- Dentro deste aspecto, o treinamento e aprimoramento de uma rede neural artificial é visado e aplicado em diversas áreas teóricas e práticas para aperfeiçoamento de resultados, como previsão de demanda em diversos setores (CAIRES & SIMONELLI; CARDOSO, 2021),


Exemplos

- Auxílio na identificação, diagnóstico e análise na área da saúde (SANTOS; SKEIKA; VOGADO, 2019);
- Estimativas e cálculos para a agropecuária (ABRAGAM, 2019; ALCÂNTRA, 2015; AZEVEDO, 2017);
- Auxílio nos estudos sobre fatores climáticos (DANTAS, 2015; MOREIRA, 2017);
- Predições dentro de estudos biológicos (MORAIS, 2010; VENDRUSCOLO, 2015)

Revisão Bibliográfica

Redes Neurais Artificiais

- O modelo algoritmo procura imitar as atividades biológicas dentro de uma célula nervosa, sendo uma simplificação do modelo de um neurônio e tendo capacidades de processamento similares (MCCULLOCH & PITTS, 1943 apud RAUBER, 2005, p. 5-6).



Fonte: Adaptado de RAUBER (2005)

Revisão Bibliográfica


Arquitetura de Rede Neural Artificial

- A arquitetura de uma Rede Neural Artificial é decisiva para resolver diferentes tipos de problemas e é determinada por quatro fatores importantes: número de camadas, número de nós por camada, tipo de conexão entre nós e a topologia da rede (FIORIN, 2011).
- O tipo Multilayer Perceptron da RNAs é uma rede que contém uma ou mais camadas intermediárias ou ocultas. Estas redes são amplamente utilizadas por serem fáceis de implementar e possuírem uma certa simplicidade (FIORIN, 2011).
- A capacidade computacional do MLP é reforçada pelas suas camadas intermediárias, permitindo trabalhar com dados que não sejam linearmente separáveis. Enquanto redes com duas ou mais camadas podem teoricamente implementar qualquer função, independentemente de ser linearmente separável ou não. A precisão dos resultados produzidos pela RNA está diretamente ligada ao número de nodos nas camadas intermediárias (CYBENKO, 1988).

Revisão Bibliográfica

Arquitetura de Rede Neural Artificial

- O MLP é exemplificado na Figura 2 com três entradas, duas camadas intermediárias com quatro neurônios cada e uma camada de saída com um único neurônio que produz uma única informação de saída (FIORIN, 2011).



Fonte: FIORIN (2011)

Revisão Bibliográfica

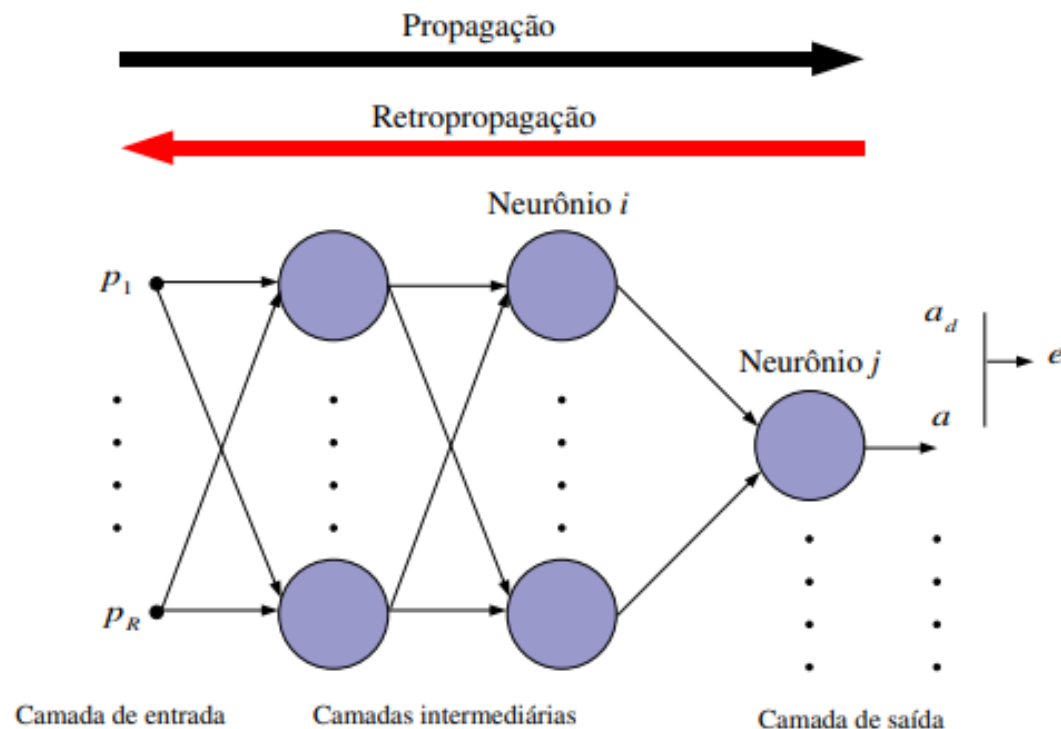
Aprendizagem de Rede Neural Artificial

- A aprendizagem em Redes Neurais é um processo descrito por Haykin (2001) que implica a adaptação dos parâmetros livres da rede em resposta ao ambiente em que a mesma está inserida. Durante este processo, a RNA é estimulada pelo ambiente e suas modificações nos parâmetros levam a uma nova resposta ao ambiente.
- Este processo de aprendizagem é realizado por meio de treinamento, que consiste em ajustes iterativos aos pesos sinápticos da RNA (MIRANDA et al., 2009).
- A rede neural extrai informações relevantes dos padrões de entrada, ajustando seus parâmetros para obter uma representação própria do problema (EYNG, 2008 apud FLECK, 2016).

Revisão Bibliográfica

Arquitetura de Rede Neural Artificial

- A Backpropagation visa encontrar a menor diferença entre as saídas desejadas e obtidas pela rede neural, com o mínimo de erro, ajustando os pesos das camadas através da retropropagação do erro (HAYKIN, 1999; RUMELHART, 1986 apud MATSUNAGA, 2012). A técnica é um tipo de treinamento supervisionado, onde a rede é avaliada durante a sua propagação e na sua retropropagação Matsunaga (2012).



Fonte: MATSUNAGA (2012)

Conjunto de Dados

Período e Quantidade

- Três anos, no intervalo de 4 de abril de 2016 até 14 de dezembro de 2018, total de 985 dias.

Valores Obtidos

- Informação do cardápio e quantidade de clientes, tanto para almoço quanto para jantar.

Tratamento dos Dados

Junção dos Dados Brutos

- Dados de cardápio, data, dia da semana e quantidade de clientes (para almoço e jantar)

Definição das Variáveis e Codificação


- Tipo do prato (agrupado em códigos de 1 à 19)
- Dia da semana (valores de 1 à 7)
- Mês (códigos de 1 à 12)
- Primeiro Semestre (código 0) ou Segundo Semestre (código 1)

Separação e Exclusão de Dados

- Separação de almoço e jantar
- Eliminação de finais de semana, feriados, etc
- Exclusão de dados incoerentes

Topologia e Treinamento da Rede Neural

- Jupyter Notebook
- Python
- TensorFlow e Keras
- 4213 pesos
- 180/1332/1332/1332/37
- ReLU ($f(x) = \max(0, x)$)
- 956 dados
- Almoço (504)
- Jantar (452)




Arquitetura	MLP
Função de Ativação	ReLU
Número de Camadas	6
Número de Neurônios na Camada de Entrada	4
Número de Neurônios nas Camadas Ocultas	36/36/36/36
Número de Neurônios na Camada de Saída	1
Função de Perda	MSE
Otimizador	Adam
Taxa de Aprendizado	0,001
Número de Épocas	10000
Validação	20%


Análise dos Resultados Almoço

- 504 dados
- 80% treinamento
- 20% teste
- Correlação Interclasse 0,9985
- 133/-133
- MSE Treino: 5,2%
- MSE Teste: 12,01%
- Média de erro de 102 clientes diariamente

Representação gráfica da correlação intraclasse entre demanda prevista e demanda real dos dados referentes ao almoço.




Representação gráfica dos erros entre a demanda prevista e demanda real dos dados referentes ao almoço.




Análise dos Resultados Jantar

- 452 dados
- 80% treinamento
- 20% teste
- Correlação Interclasse 0,9972
- 66/-65
- MSE Treino: 7,36%
- MSE Teste: 11,67%
- Média de erro de 39 clientes diariamente

Representação gráfica da correlação intraclasse entre demanda prevista e demanda real dos dados referentes ao jantar.



Representação gráfica dos erros entre a demanda prevista e demanda real dos dados referentes ao jantar.




Influência do Tratamento dos Dados Almoço


- 504 para 394 dados
- 80% treinamento
- 20% teste
- Correlação Interclasse 0,9985 para 0,9999
- 133/-133

- MSE Treino: 5,2% para 1,66%
- MSE Teste: 12,01% para 6,04%
- Média de erro de 102 para 59 clientes diariamente

Representação gráfica da correlação intraclass entre demanda prevista e demanda real dos dados referentes ao almoço sem outliers.



Representação gráfica dos erros entre a demanda prevista e demanda real dos dados referentes ao almoço sem outliers.




Influência do Tratamento dos Dados Jantar


- 452 para 365 dados
- 80% treinamento
- 20% teste
- Correlação Interclasse 0,9972 para 0,9996
- 66/-65

- MSE Treino: 7,36% para 3,28%
- MSE Teste: 11,67% para 6,8%
- Média de erro de 39 para 22 clientes diariamente

Representação gráfica da correlação intraclass entre demanda prevista e demanda real dos dados referentes ao jantar sem outliers.



Representação gráfica dos erros entre a demanda prevista e demanda real dos dados referentes ao jantar sem outliers.



Conclusão

Resultados Satisfatórios

- 12% MSE;
- 102 media de erro – almoço;
- 39 media de erro – jantar.

Influência do Tratamento dos Dados

- Grande diminuição do erro.

Recomendações

- Melhor tratamento de dados;
- Integração com banco de dados;
- Continuidade do Projeto.

Referências

ABRAHAM, Emerson Rodolfo et al. Estimativa da produção da soja brasileira utilizando redes neurais artificiais. *Agrarian*, v. 12, n. 44, p. 261-271, 2019.

ABREU, Edeli Simioni; SPINELLI, Mônica Glória Neuman; ZANARDI, Ana Maria Pinto. *Gestão de Unidades de Alimentação e Nutrição: Um modo de fazer*. São Paulo: Metha, 2007.

ALCÂNTARA, Aline Edwiges Mazon de. *Redes neurais artificiais para prognose do crescimento e da produção de povoamentos de eucalipto em Minas Gerais*. 2015.

AZEVEDO, Alcinei M. et al. Eficiência da estimação da área foliar de couve por meio de redes neurais artificiais. *Horticultura Brasileira*, v. 35, p. 14-19, 2017.

CAIRES, Kaique Vitor Louzada; SIMONELLI, George. Previsão da demanda brasileira de biodiesel utilizando redes neurais artificiais. *Research, Society and Development*, v. 10, n. 5, p. e17410513381-e17410513381, 2021.

CARDOSO, R.C.V.; SOUZA, E.V.A.; SANTOS, P.Q. Unidades de alimentação e nutrição nos campus da Universidade Federal da Bahia: um estudo sob a perspectiva do alimento seguro. *Revista de Nutrição*, v. 18, n. 5, p.670, set./out. 2005.

CYBENKO, G. Continuous valued neural networks with two hidden layer are sufficient, Tufts University. Medford. (Technical Report), 1988.

DANTAS, Daniel et al. Uso de Redes Neurais Artificiais na previsão da precipitação de períodos chuvosos. *Revista Espinhaço*, 2015.

EYNG, E. Controle Feedforward-Feedback aplicado às colunas de absorção de produção de etanol por fermentação. 2008. Campinas, SP. Tese (Doutorado) – Programa de Pós-Graduação em Engenharia Química, Universidade Estadual de Campinas.

FIORIN, Daniel V. et al. Aplicações de redes neurais e previsões de disponibilidade de recursos energéticos solares. *Revista Brasileira de Ensino de Física*, v. 33, p. 01-20, 2011.

HAYKIN, S. *Neural Networks: a comprehensive foundation*. New York: MacMillan College Publishing Co., 1999.

HAYKIN, S. *Redes neurais: princípios e prática*. 2ª Edição. Porto Alegre: Bookman, 2001.

KOTLER, Philip. Administração de marketing: análise, planejamento, implementação e controle. In: *Administração de marketing: análise, planejamento, implementação e controle*. 1994.

Referências

MATSUNAGA, Victoria Yukie. Curso de Redes Neurais utilizando o MATLAB. Belém do Pará, 2012.

MCCULLOCH, Warren S.; PITTS, Walter. A logical calculus of the ideas immanent in nervous activity. The bulletin of mathematical biophysics, v. 5, p. 115-133, 1943.

MIRANDA, F. A.; FREITAS, S. R. C.; FAGGION, P. L. Integração e interpolação de dados de anomalias ar livre utilizando-se a técnica de RNA e krigagem. Boletim de Ciências Geodésicas, v.15, n.3, p. 428-443, 2009.

MORAIS, Emerson Cordeiro. Reconhecimento de padrões e redes neurais artificiais em predição de estruturas secundárias de proteínas. Universidade Federal do Rio de Janeiro. Programa de Engenharia de Sistemas e Computação. Rio de Janeiro, 2010.

MOREIRA, Artur Ferreira et al. Utilização de uma Rede Neural Artificial como Algoritmo de Controle de um Robô Ackerman em Ambiente Simulado. Mostra Nacional de Robótica., 2017.

RAUBER, Thomas Walter. Redes neurais artificiais. Universidade Federal do Espírito Santo, v. 29, 2005.

RUMELHART, David E.; HINTON, Geoffrey E.; WILLIAMS, Ronald J. Learning representations by back-propagating errors. nature, v. 323, n. 6088, p. 533-536, 1986.

SANTOS, Hellen Geremias dos et al. Machine learning para análises preditivas em saúde: exemplo de aplicação para predizer óbito em idosos de São Paulo, Brasil. Cadernos de Saúde Pública, v. 35, p. e00050818, 2019.

SKEIKA, Everton Leonardo et al. Utilização de redes neurais completamente convolucionais para identificação e medição de crânios fetais., 2019. Dissertação de Mestrado. Universidade Tecnológica Federal do Paraná.

VENDRUSCOLO, Diogo Guido Streck et al. Estimativa da altura de eucalipto por meio de regressão não linear e redes neurais artificiais. Revista brasileira de biometria, v. 33, n. 4, p. 556-569, 2015.

VOGADO, Luis HS et al. Rede neural convolucional para o diagnóstico de leucemia. In: Anais do XIX Simpósio Brasileiro de Computação Aplicada à Saúde. SBC, 2019. p. 46-57.

Obrigado!

